

Computational Intelligence

Einkriterielle Evolutionäre Algorithmen II

Dr. Carsten Franke

Zürcher Hochschule für Angewandte Wissenschaften

24. Februar 2015

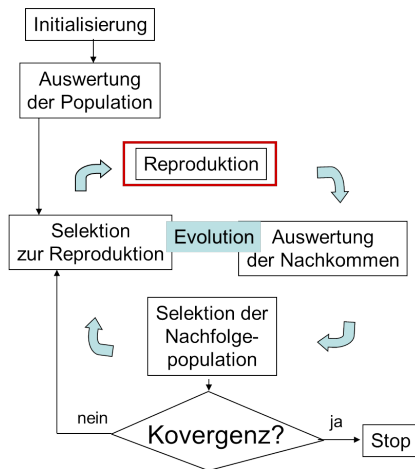
Vorlesungsplanung - Termine (Änderungen vorbehalten)

- 1 17.02.2015: Einkriterielle Evolutionäre Optimierung I (CF)
- 2 24.02.2015: Einkriterielle Evolutionäre Optimierung II (CF)
- 3 03.03.2015: **Test (1+2)**, Mehrkriterielle Evolutionäre Optimierung I (CF)
- 4 10.03.2015: Mehrkriterielle Evolutionäre Optimierung II (CF)
- 5 17.03.2015: Statistische Lerntheorie I (JP)
- 6 24.03.2015: Statistische Lerntheorie II (JP)
- 7 21.04.2015: **Test (5+6)**, Neuronale Netze (JP)
- 8 28.04.2015: Support Vector Maschinen I (JP)
- 9 05.05.2015: Genetische Fuzzy Systeme (CF)
- 10 12.05.2015: **Test (3+4+9)**, Meta-Heuristiken (ACO, PSO) (CF)
- 11 19.05.2015: Support Vector Maschinen II (JP)
- 12 26.05.2015: Simulated Annealing und andere Suchmethoden (CF)
- 13 02.06.2015: **Test (7+8+11)**, Clustering (JP)
- 14 09.06.2015: Lernen und Spieltheorie (JP)
- 15 23.06.2015: 1. Termin mündliche Prüfungen
- 16 30.06.2015: 2. Termin mündliche Prüfungen

- Schriftlicher Test von ca. 30 min Länge
- Erlaubte Hilfsmittel: Vorlesungsfolien + eigene Mitschriften, Taschenrechner
- **Nicht** erlaubte Hilfsmittel: Laptop, Natel

- Erlernen der restlichen Operatoren für Evolutionäre Algorithmen
- Ausführung eines ersten Genetischen Algorithmus
- Erlernen der Funktionsweise von Evolutionsstrategien
- Erlernen der Selbstadaptionmechanismen für Evolutionsstrategien

Allgemeiner Ablauf



- **Initialisierung**

- Kodierung

- **Evaluation**

- Fitnesswert

- **Reproduktion**

- Rekombination, Mutation

- **Konvergenz**


- z.B. fixe Generationsanzahl

Mit Wahrscheinlichkeit p_m wird ein Objektparametervektor einer Mutation unterzogen.

- Neuer Objektparametervektor für das k -te Individuum: $\tilde{\vec{o}}_k = \vec{o}_k + \vec{z}$
- Es wird angenommen, dass \vec{o}_k und \vec{z} jeweils u Elemente hat.
- Es werden zwei verschiedene Verfahren unterschieden:
 - Isotropische Mutation: $\vec{z} = \sigma(\mathcal{N}_1(0, 1), \dots, \mathcal{N}_u(0, 1))$
 - Nicht-isotropische Mutation: $\vec{z} = (\sigma_1 \mathcal{N}_1(0, 1), \dots, \sigma_u \mathcal{N}_u(0, 1))$
- $\mathcal{N}(0, 1)$ bezeichnet dabei unabhängige Samples der Normalverteilung.
- Damit ergibt sich für den neuen Parametervektor folgende

$$\text{Dichtefunktion: } p(\tilde{o}_k) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2} \frac{(\tilde{o}_k - o_k)^2}{\sigma^2}}$$

Normalverteilung




- $\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2} \frac{(x-\mu)^2}{\sigma^2}}$
- $\mu = 0, \sigma = 1$
- $\mu = 0, \sigma = 1.5$
- $\mu = 0, \sigma = 0.2$
- $\mu = 1, \sigma = 1$
- Integral über den ganzen Wertebereich ist stets 1


Polynomielle Mutation:

- Neuer Objektparametervektor: $\tilde{o}_k = o_k + \left(o_k^{(U)} - o_k^{(L)}\right) \delta_k$
- Wähle $r_k \in [0, 1]$ und $\eta_m \geq 0$
- Bestimme $\delta_k = \begin{cases} (2r_k)^{1/(\eta_m+1)} - 1, & \text{if } r_k < 0.5 \\ 1 - [2(1 - r_k)]^{1/(\eta_m+1)}, & \text{if } r_k \geq 0.5 \end{cases}$


Mutationen bei Sequenzen



Move



Jump



Swap

Mutationen bei Sequenzen

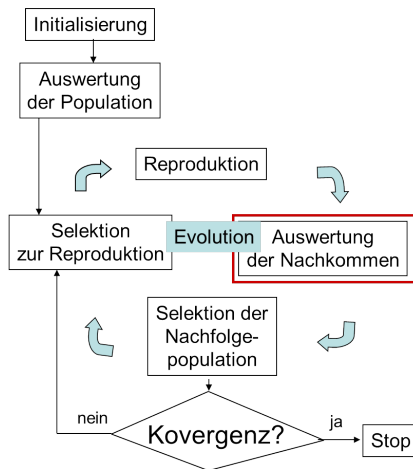
- Probleme dabei sind die noch nicht bekannten Anzahlen der Mutationen und die jeweiligen Distanzen.
- Eingabe
 - Durchschnittliche Mutationsanzahl: DMZ
 - Durchschnittliche Distanz: DD
- Ausgabe
 - Mutationsanzahl: MZ
 - Distanz: D
- Berechnung
 - $MZ = \left\lfloor \frac{ld(1-s_1)}{ld(1-p_{MZ})} \right\rfloor$, mit $p_{MZ} = 1 - \frac{DMZ}{1+\sqrt{1+DMZ^2}}$
 - $D = \left\lfloor \frac{ld(1-s_2)}{ld(1-p_D)} \right\rfloor$, mit $p_D = 1 - \frac{DD}{1+\sqrt{1+DD^2}}$

Übung Implementierung

Implementieren Sie bitte:

- 1 Funktion, die an einem gegebenen binären String eine Mutation mit Wahrscheinlichkeit p_m vornimmt.
- Wenden Sie diese Funktion auf alle lokalen Individuen an. Das Resultat bildet die Menge der Nachkommen.

Auswertung der Nachkommen



- **Initialisierung**

- Kodierung

- **Evaluation**

- Fitnesswert

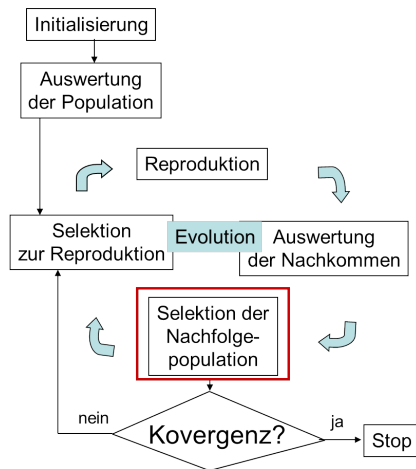
- **Reproduktion**

- Rekombination, Mutation

- **Konvergenz**

- z.B. fixe Generationsanzahl

Auswertung der Nachkommen



- **Initialisierung**

- Kodierung

- **Evaluation**

- Fitnesswert

- **Reproduktion**

- Rekombination, Mutation

- **Konvergenz**

- z.B. fixe Generationsanzahl

- Genetisch Algorithmen
 - Es werden nur die Nachkommen für die nächste Generation genutzt. Die Nachkommenanzahl wurde bei der Rekombination beachtet.
($\mu = \lambda$)
- Evolutionsstrategien
 - Verfahrensweise gemäss: ($\mu, \kappa, \lambda, \rho$)

Übung

Beschreiben Sie mit eigenen Worten die Parameter $(\mu, \kappa, \lambda, \rho)$!

Selektion bei Evolutionsstrategien

- μ : Populationsgrösse der Eltern
- λ : Populationsgrösse der Nachkommen ($\lambda \geq \mu$)
- κ : maximale Anzahl von Lebenszyklen pro Individuum
- ρ : Anzahl der Eltern bei der Rekombination

Algorithmus:

if ($\kappa = 1$) **then**

$P_{(t+1),\mu} \leftarrow \text{Selektion } (P'_{t,\lambda}, \mu); \{\text{nicht - elitär}\}$

else if ($\kappa = \infty$) **then**

$P_{(t+1),\mu} \leftarrow \text{Selektion } (P'_{t,\lambda} \cup P_{t,\mu}, \mu); \{\text{elitär}\}$

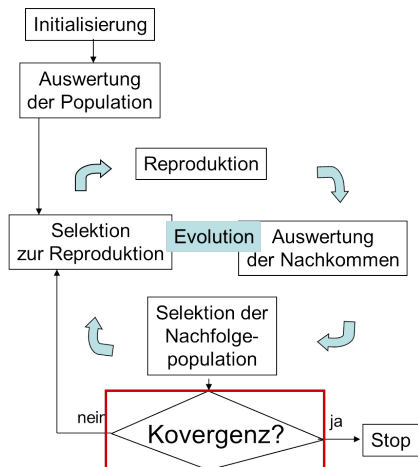
else

$P_{(t+1),\mu} \leftarrow \text{Selektion } (P'_{t,\lambda} \cup P_{t,\mu}, \mu, \kappa); \{\text{nicht - elitär}\}$

end if

Übung

Welche Verfahren könnten für die Selektion genutzt werden? Sind die jeweiligen Verfahren dann elitär oder nicht?



- **Initialisierung**

- Kodierung

- **Evaluation**

- Fitnesswert

- **Reproduktion**

- Rekombination, Mutation

- **Konvergenz**

- z.B. fixe Generationsanzahl

- Es gibt eine im Prinzip unendliche Anzahl möglicher Kriterien. Gebräuchlich sind unter anderem:
 - Fixe Generationenanzahl
 - Unterschreitung eines Deltas bzgl. der Verbesserung der Fitnessfunktion innerhalb einer gewissen Anzahl von Generationen

Implementieren Sie einen GA für das bekannte Zylinderproblem

- Initialisierung von 30 Individuen zufällig (binär)
- Auswertung aller 30 Individuen
- For i=1 to 100 //Generationen
 - Rang-basierte Selektion (Individuen müssen Nebenbedingungen erfüllen)
 - Mutation mit $pm=10\%$ für die selektierte Menge
 - **keine Rekombination**
 - Auswertung der Individuen
 - Speicherung des besten Individuums bzgl. $f(x)$ in einem separaten Bereich (für jede Generation ein Individuum)
- Darstellung des Werteverlaufs des jeweils besten Individuums über die 100 Generationen. Was ist die beste gefundene Lösung in (d,h) und welchen Funktionswert hat diese?

Übung

- Wiederholen Sie den vorherigen Algorithmus für $p_m = \{1\%, 0.5\%, 2\%, 10\%, 20\%\}$.
- Lassen sich Aussagen bezüglich p_m treffen? Wie gross sollte dieser Wert gewählt werden?

Implementieren Sie einen GA für das bekannte Zylinderproblem

- Initialisierung von 30 Individuen zufällig (binär)
- Auswertung aller 30 Individuen
- For i=1 to 100 //Generationen
 - Rang-basierte Selektion (Individuen müssen Nebenbedingungen erfüllen)
 - **Rekombination von 10 zufällig ausgewählten Individuen mittels Single-Point Crossover**. Die Eltern werden hier durch die Nachkommen ersetzt.
 - Nutzen Sie die Rekombination, um die Anzahl der Nachkommen mit 30 Individuen sicherzustellen
 - Mutation mit $pm=1\%$ für die **resultierende** Menge
 - Auswertung der Individuen
 - Speicherung des besten Individuums bzgl. $f(x)$ in einem separaten Bereich (für jede Generation ein Individuum)
- Darstellung des Werteverlaufs des jeweils besten Individuums über die 100 Generationen. Was ist die beste gefundene Lösung in (d,h) und welchen Funktionswert hat diese?

Rahmenparameter

- Objektparameter (Problemkodierung): \vec{o}_k
- Strategieparameter (Mutation/ Rekombination/ Selektion): \vec{s}_k
- Fitness: $F(\vec{o}_k)$
- Populationsgrösse zum Zeitpunkt t: $\mu = |P_{t,\mu}|$
- Anzahl Nachkommen: λ
- Anzahl Eltern bei der Rekombination: ρ
- Maximale Anzahl von Generationen pro Individuum: κ

Parameter	Genetische Algorithmen	Evolutionstrategien
Individuen	$a_k = (\vec{o}_k, F(\vec{o}_k))$	$a_k = (\vec{o}_k, \vec{s}_k, F(\vec{o}_k))$
Populationsgrösse / Nachkommen	$\mu = \lambda$	$\mu/\lambda = 1/7$
max Anzahl Generationen pro Individuum	$\kappa = 1$	$\kappa \in [1, \infty[$
Strategieparameter	fix	selbstanpassend

Übung

- Beschreiben Sie **eine** mögliche **Selektion der Nachfolgepopulation** für einen Genetischen Algorithmus!
- Beschreiben Sie **eine** mögliche **Selektion der Nachfolgepopulation** für eine Evolutionsstrategie!

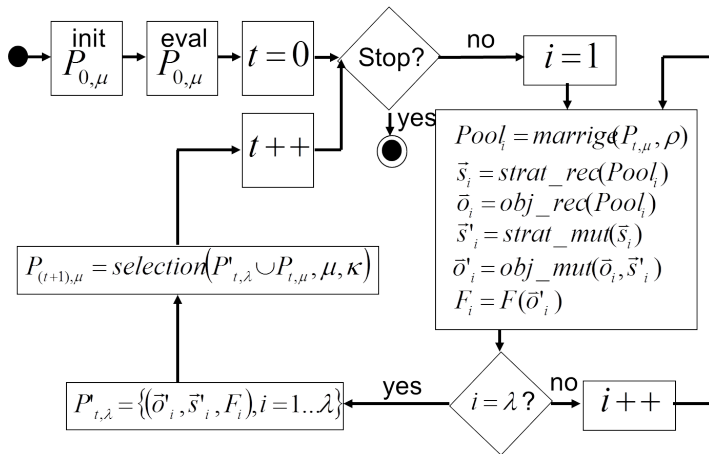
- **Exogene** Strategieparameter

- konstant während der gesamten Optimierung
- z.B. $(\mu, \kappa, \lambda, \rho)$

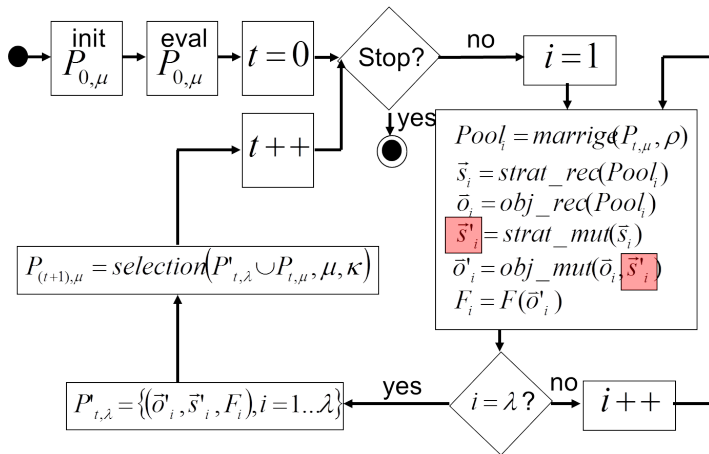
- **Endogene** Strategieparameter

- passen sich während der Optimierung an
- Beispiele
 - Mutations- / und Rekombinationswahrscheinlichkeiten
 - Schrittweitenparameter bei einzelnen Operatoren

Ablauf einer $(\mu, \kappa, \lambda, \rho)$ Evolutionsstrategie



Ablauf einer $(\mu, \kappa, \lambda, \rho)$ Evolutionsstrategie



Ablauf einer $(\mu, \kappa, \lambda, \rho)$ Evolutionsstrategie

$P_{0,\mu} \leftarrow$ initialization;

$P_{0,\mu} \leftarrow$ evaluation;

$t \leftarrow 0$;

while (termination criterion not fulfilled) **do**

for ($i = 1$ to λ) **do**

$Pool_i \leftarrow$ marriage ($P_{t,\mu}, \rho$);

$\vec{s}_i \leftarrow$ strategy_recombination ($Pool_i$);

$\vec{o}_i \leftarrow$ object_recombination ($Pool_i$);

$\tilde{s}_i \leftarrow$ strategy_mutation (\vec{s}_i);

$\tilde{o}_i \leftarrow$ object_mutation (\tilde{s}_i, \vec{o}_i);

$\tilde{F}_i \leftarrow F(\tilde{o})$

end for

 Teil 2

$t \leftarrow t + 1$

end while

Ablauf einer $(\mu, \kappa, \lambda, \rho)$ Evolutionsstrategie

Teil 1

while (termination criterion not fulfilled) **do**

Teil 1

$P'_{t,\lambda} \leftarrow \left\{ \left(\tilde{o}_i, \tilde{s}_i, \tilde{F}_i \right), i = 1, \dots, \lambda \right\};$

if $(\kappa = 1)$ **then**

$P_{(t+1),\mu} \leftarrow \text{selection} (P'_{t,\lambda}, \mu);$

else if $(\kappa = \infty)$ **then**

$P_{(t+1),\mu} \leftarrow \text{selection} (P'_{t,\lambda} \cup P_{t,\mu}, \mu);$

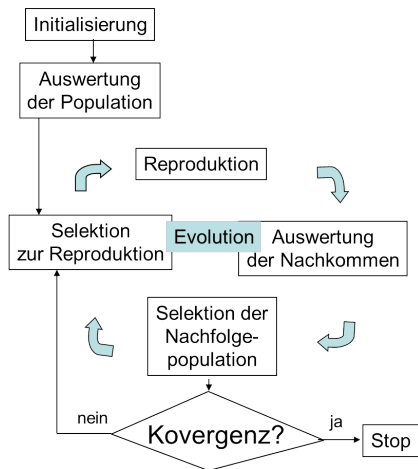
else

$P_{(t+1),\mu} \leftarrow \text{selection} (P'_{t,\lambda} \cup P_{t,\mu}, \mu, \kappa);$

end if

$t \leftarrow t + 1$

end while



- Wo finden Sie entsprechende Elemente in der Beschreibung der Evolutionsstrategie?

Selbstanpassung

Der Erfolg einer ES hängt stark von der Selbstanpassung der Strategieparameter ab, die auf veränderte Suchräume reagiert.

- zum Beispiel Mutation: $\tilde{\vec{o}}_k = \vec{o}_k + \vec{z}$
- Es wird angenommen, dass \vec{o}_k und \vec{z} jeweils u Elemente haben.
- Nicht-isotropische Mutation: $\vec{z} = (\sigma_1 \mathcal{N}_1(0, 1), \dots, \sigma_u \mathcal{N}_u(0, 1))$
- Selbstadaption verändert nun $\sigma_1, \dots, \sigma_u$

1/5 Regel (original nur für $(\mu = 1, \lambda = 1, \kappa = \infty)$ Strategien)

$$P_s = \frac{\text{Anzahl erfolgreicher Mutationen}}{\text{Anzahl aller Mutationen}}$$

$$\tilde{\sigma} = \begin{cases} \sigma/a, & \text{falls } P_s > 1/5 \\ \sigma \cdot a, & \text{falls } P_s < 1/5 \\ \sigma, & \text{falls } P_s = 1/5 \end{cases}$$

Der Parameter a wird folgendermassen gewählt: $0,85 \leq a < 1$

Übung

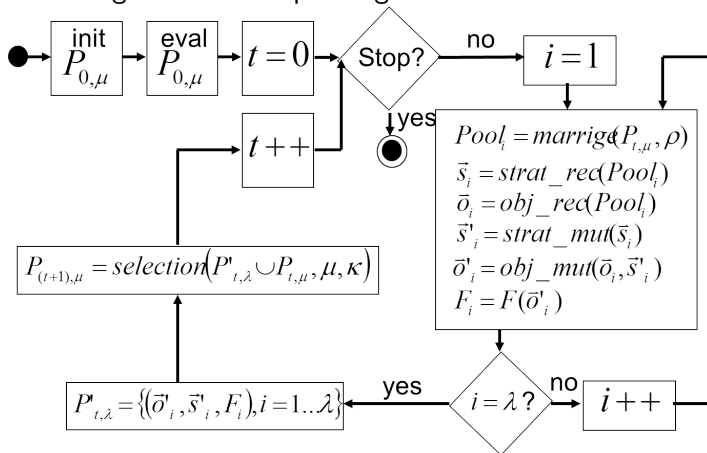
Nehmen Sie die Nutzung der 1/5 Regel an. Welche Aussage(n) ist/sind richtig?

- Wenn 1/5 der letzten Mutationen erfolgreich war, dann wird danach eher lokal gesucht.
- Wenn 1/5 der letzten Mutationen erfolgreich war, dann wird danach eher global gesucht.
- Bei vielen erfolglosen Mutationen wird das Suchgebiet vergrössert um bessere Lösungen zu finden.

- Isotropische Mutation ($\vec{z} = \sigma(\mathcal{N}_1(0, 1), \dots, \mathcal{N}_u(0, 1))$):
 - $\tilde{\sigma} = \sigma \cdot e^{\tau \mathcal{N}(0,1)}$
 - Lernrate: $\tau \propto \frac{1}{\sqrt{u}}$
 - Lernrate bei vielen Objektparametern: $\tau \propto \frac{1}{\sqrt{2 \cdot u}}$
- Nicht-isotropische Mutation ($\vec{z} = (\sigma_1 \mathcal{N}_1(0, 1), \dots, \sigma_u \mathcal{N}_u(0, 1))$):
 - $\tilde{\vec{\sigma}} = e^{\tau_0 \mathcal{N}(0,1)} \cdot (\sigma_1 \cdot e^{\tau_1 \mathcal{N}_1(0,1)}, \dots, \sigma_u \cdot e^{\tau_1 \mathcal{N}_u(0,1)})$
 - Lernraten:

$$\tau_0 = \frac{1}{\sqrt{2 \cdot u}}, \text{ and } \tau_1 = \frac{1}{\sqrt{2 \sqrt{u}}}$$

Wo erfolgt die Selbstanpassung?



Übung

- Implementieren Sie das bekannte Zylinderproblem mittels einer 100-Generationen Evolutionsstrategie $(\mu, \kappa, \lambda, \rho) = (7, 15, 49, 3)$
- Objektparameter
 - Durchschnittliche Rekombination
 - Isotropic Mutation (Start 1%) mit $\tau = \frac{1}{\sqrt{u}}$
- Strategieparameter
 - Diskrete Rekombination
 - Non-Isotropic Mutation (Start 1%) mit

$$\tau_0 = \frac{1}{\sqrt{2 \cdot u}}, \text{ and } \tau_1 = \frac{1}{\sqrt{2\sqrt{u}}}$$

- Zeigen Sie den Verlauf des besten Individuums pro Generation.

Wann sollte was wie genutzt werden?

- Genetische Algorithmen: für diskrete Suchräume
- Evolutionsstrategien: für kontinuierliche Suchräume
 - Falls ES in diskreten Suchräumen genutzt wird: $(\mu, \lambda, \kappa = 1, \rho)$
- **NICHT** als reines Black-Box Optimierungstool
 - Problemkodierung ist sehr wichtig
 - Mutation/Rekombination/Selektion Methoden
 - Methodenparameter, z.B. Mutationsstärke, Rekombinationswahrscheinlichkeiten
- Aber im Allgemeinen sehr mächtig und flexibel!

Hausaufgaben

- Beenden Sie **alle** Beispiele, die Sie während der Vorlesung nicht fertig gestellt haben!
- Dies ist sehr wichtig, da die nachfolgende Vorlesung darauf aufbauen wird.
- Überprüfung zu Beginn der nächsten Vorlesung.
- Durcharbeiten des Papers „Evolution Strategies: A comprehensive introduction“. Lesen Sie dabei die Kapitel: 3.1, 3.2, 3.3 (erster Teil), 3.3.2.1, 3.4.1, 4.1.2, 4.2.2.1 und 4.2.2.2.

Vorlesungsplanung - Termine (Änderungen vorbehalten)

- ❶ 17.02.2015: Einkriterielle Evolutionäre Optimierung I (CF)
- ❷ 24.02.2015: Einkriterielle Evolutionäre Optimierung II (CF)
- ❸ 03.03.2015: **Test (1+2)**, Mehrkriterielle Evolutionäre Optimierung I (CF)
- ❹ 10.03.2015: Mehrkriterielle Evolutionäre Optimierung II (CF)
- ❺ 17.03.2015: Statistische Lerntheorie I (JP)
- ❻ 24.03.2015: Statistische Lerntheorie II (JP)
- ❼ 21.04.2015: **Test (5+6)**, Neuronale Netze (JP)
- ❽ 28.04.2015: Support Vector Maschinen I (JP)
- ❾ 05.05.2015: Genetische Fuzzy Systeme (CF)
- ❿ 12.05.2015: **Test (3+4+9)**, Meta-Heuristiken (ACO, PSO) (CF)
- ⓫ 19.05.2015: Support Vector Maschinen II (JP)
- ⓬ 26.05.2015: Simulated Annealing und andere Suchmethoden (CF)
- ⓭ 02.06.2015: **Test (7+8+11)**, Clustering (JP)
- ⓮ 09.06.2015: Lernen und Spieltheorie (JP)
- ⓯ 23.06.2015: 1. Termin mündliche Prüfungen
- ⓰ 30.06.2015: 2. Termin mündliche Prüfungen